

OPTIMISATION DU CHOIX ANTIBIOTIQUE EN MILIEU CLINIQUE PAR APPRENTISSAGE AUTOMATIQUE APPLIQUÉ AUX DONNÉES GÉNOMIQUES BACTÉRIENNES

Présenté par : EL GAMOUNE Elyes Formation : Licence Informatique option Mathématiques

1. Introduction

La résistance aux antibiotiques est un problème de santé publique qui prend de plus en plus d'ampleur. L'OMS estime qu'elle est responsable d'environ 1,27 million de décès par an dans le monde, et les chiffres pourraient atteindre 10 millions par an d'ici 2050 si rien ne change. C'est un chiffre qui donne le vertige, surtout quand on sait qu'une grande partie de ces décès pourrait être évitée avec un meilleur usage des antibiotiques existants.

Le problème est : quand un patient arrive aux urgences avec une infection bactérienne, le médecin ne sait pas encore quelle bactérie est en cause ni si elle est résistante. Il prescrit donc un antibiotique de manière empirique, c'est-à-dire en se basant sur les données épidémiologiques locales et son expérience clinique, en attendant les résultats de l'antibiogramme (un test de laboratoire qui nécessite entre 24 et 72 heures de culture bactérienne). Ce délai n'est pas anodin : il contribue à l'aggravation des patients et surtout à la prescription inutile d'antibiotiques à large spectre, ce qui accélère l'apparition de nouvelles résistances.

Aujourd'hui, le séquençage du génome bactérien est devenu plus rapide et moins cher, ce qui ouvre une vraie opportunité : analyser directement l'ADN d'une bactérie pour prédire si elle va résister à tel ou tel antibiotique, sans attendre la culture en laboratoire. Et c'est là que le machine learning entre en jeu : les génomes bactériens génèrent des données massives et complexes, exactement le type de données sur lequel les algorithmes d'apprentissage automatique peuvent se montrer très efficaces.

Problématique : Dans quelle mesure les modèles d'apprentissage automatique appliqués aux données génomiques bactériennes permettent-ils d'optimiser le choix de l'antibiothérapie en contexte clinique, en complément ou en remplacement de l'antibiogramme conventionnel ?

2. État de l'art

2.1 Le génome bactérien comme source d'information

Le séquençage complet du génome bactérien (WGS, Whole Genome Sequencing) permet d'identifier les gènes de résistance portés par une bactérie, qu'ils soient intégrés dans son chromosome ou sur des éléments mobiles comme les plasmides. Ces gènes, qu'on appelle ARGs (Antimicrobial Resistance Genes), sont bien répertoriés dans des bases de données publiques comme CARD (Comprehensive Antibiotic Resistance Database) ou ResFinder, qui font le lien entre la présence d'un gène et la résistance à un antibiotique donné.

Ce qui est intéressant, c'est que la résistance n'est pas toujours liée à un seul gène bien identifié, elle peut résulter de l'interaction de plusieurs mutations, ce qui rend la prédiction difficile à faire "à la main" et justifie justement l'usage du machine learning.

2.2 Ce qui a déjà été fait en ML

Plusieurs équipes ont montré que c'était faisable. Moradigaravand et al. (2018) ont obtenu plus de 90% de précision en utilisant des modèles de random forest pour prédire la résistance d'*Escherichia coli* à plusieurs antibiotiques, uniquement à partir de données génomiques.

D'autres approches utilisent des réseaux de neurones convolutifs (CNN) appliqués directement aux séquences ADN encodées, pour capturer des motifs de résistance plus complexes que ce qu'on peut voir avec des méthodes classiques.

Des outils comme Kover ou PanRec vont encore plus loin en travaillant sur le génome panmicrobien, c'est-à-dire en tenant compte de toute la diversité génétique d'une espèce bactérienne, ce qui leur permet de détecter des mécanismes de résistance émergents, même ceux pas encore connus. Ces travaux ont été appliqués à des pathogènes prioritaires comme *Mycobacterium tuberculosis*, *Klebsiella pneumoniae* ou *Staphylococcus aureus*, avec des résultats comparables à ceux de l'antibiogramme classique.

2.3 Les limites actuelles

Malgré ces résultats encourageants, plusieurs problèmes freinent encore l'utilisation de ces modèles en conditions réelles. D'abord, les modèles sont souvent peu généralisables : entraînés sur des bactéries d'une région du monde, ils marchent moins bien sur des souches d'une autre région, à cause de la diversité génétique des bactéries. Ensuite, l'interprétabilité pose problème, un médecin a besoin de comprendre pourquoi le modèle dit qu'une bactérie est résistante, pas juste d'avoir un score. Enfin, les données d'entraînement disponibles publiquement sont souvent déséquilibrées, avec une surreprésentation des souches résistantes, ce qui peut fausser les performances réelles en hôpital.

3. Approche et méthodologie envisagée

3.1 Objectif

L'idée de ce projet serait de construire un pipeline de machine learning qui prend en entrée des données de séquençage génomique d'une bactérie pathogène, et qui produit en sortie une recommandation sur les antibiotiques à utiliser, classés par probabilité d'efficacité. L'aspect différenciant par rapport à ce qui existe déjà serait d'ajouter une explication interprétable de la prédiction, accessible à un clinicien qui n'a pas de formation en data science.

3.2 Données

Le projet s'appuierait sur des données publiques disponibles dans PATRIC/BV-BRC et l'European Nucleotide Archive (ENA), qui contiennent des dizaines de milliers de génomes bactériens associés à leurs profils de résistance mesurés en laboratoire. On se concentrerait sur deux bactéries prioritaires : *Klebsiella pneumoniae* (résistances aux carbapénèmes, problème majeur en milieu hospitalier) et *Escherichia coli* (résistances aux fluoroquinolones et céphalosporines, très fréquentes en médecine de ville).

3.3 Pipeline technique

Le travail se déroulerait en quatre étapes principales. La première serait le prétraitement des données : assemblage des génomes bruts, annotation avec l'outil Prokka, et extraction des variants génétiques (SNPs) et des k-mers caractéristiques. La deuxième étape serait la construction des features : représentation vectorielle des génomes à partir de la présence ou absence des gènes de résistance connus (via CARD) et des profils de k-mers. La troisième étape serait la modélisation : comparaison de plusieurs algorithmes: Random Forest, XGBoost et un réseau de neurones fully connected (MLP, Multilayer Perceptron), avec une validation croisée stratifiée pour ne pas être trompé par le déséquilibre des classes. Enfin, la quatrième étape porterait sur l'interprétabilité : utilisation de la méthode SHAP (SHapley Additive exPlanations) pour identifier quels éléments génomiques influencent le plus la prédiction, avec une sortie lisible par un non-spécialiste.

3.4 Évaluation

Les métriques retenues ne se limiteraient pas à la précision globale. On privilégierait la sensibilité (pour minimiser le risque de prescrire un antibiotique inefficace, ce qui est cliniquement dangereux) et l'AUC-ROC par classe d'antibiotique, complétées par le score F1 pondéré pour gérer les déséquilibres entre classes.

4. Enjeux, limites et perspectives

4.1 Aspects éthiques et réglementaires

Même si on travaille sur des génomes bactériens et non directement sur des données patients, des questions éthiques se posent : le génome d'un pathogène peut indirectement révéler des informations sur le patient porteur. Le traitement de ces données en milieu hospitalier devrait se conformer au RGPD et aux recommandations de la CNIL sur les données de santé. Par ailleurs, tout outil d'aide à la décision en médecine devra passer par un processus de validation clinique rigoureux avant d'être utilisé en pratique.

4.2 Limites techniques

La principale contrainte reste le temps de séquençage : même avec les technologies les plus récentes comme Oxford Nanopore, il faut encore 4 à 6 heures dans les meilleures conditions. C'est moins que l'antibiogramme classique, mais ça suppose que les hôpitaux soient équipés, ce qui est loin d'être le cas partout. La robustesse des modèles face à des bactéries très variables génétiquement, ou portant de nombreux plasmides, reste aussi un défi technique ouvert.

4.3 Perspectives

À plus long terme, ce type d'approche pourrait s'intégrer dans des systèmes de surveillance épidémiologique en temps réel, permettant de cartographier la progression des résistances à l'échelle d'un pays ou d'une région. L'extension vers des modèles multimodaux, combinant données génomiques, données cliniques du patient et données environnementales, représente une piste de recherche particulièrement intéressante pour les années à venir.

5. Bibliographie

- Moradigaravand, D. et al. (2018). Prediction of antibiotic resistance in *Escherichia coli* from large-scale pan-genome data. *PLOS Computational Biology*, 14(12).
- Nguyen, M. et al. (2019). Developing an in silico minimum inhibitory concentration panel test for *Klebsiella pneumoniae*. *Scientific Reports*, 9, 8673.
- Arango-Argoty, G. et al. (2018). DeepARG: a deep learning approach for predicting antibiotic resistance genes from metagenomic data. *Microbiome*, 6(1), 23.
- Drouin, A. et al. (2019). Interpretable genotype-to-phenotype classifiers with performance guarantees. *Scientific Reports*, 9, 4071.
- Břinda, K. et al. (2020). Rapid inference of antibiotic resistance and susceptibility by genomic neighbour typing. *Nature Microbiology*, 5, 455-464.
- WHO (2023). Global Antimicrobial Resistance and Use Surveillance System (GLASS) Report. World Health Organization, Geneva.
- Lundberg, S. M. & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- Alcock, B. P. et al. (2023). CARD 2023: expanded curation, support for machine learning, and resistome prediction. *Nucleic Acids Research*, 51(D1).